



矩阵求导术（下）



长驱鬼侠
数学爱好者

已关注

王赞 Maigo 等 1,342 人赞同了该文章

本文承接上篇 zhuanlan.zhihu.com/p/24...，来讲矩阵对矩阵的求导术。使用小写字母 x 表示标量，粗体小写字母 \boldsymbol{x} 表示列向量，大写字母 X 表示矩阵。矩阵对矩阵的求导采用了向量化的思路，常应用于二阶方法中Hessian矩阵的分析。

首先来琢磨一下定义。矩阵对矩阵的导数，需要什么样的定义？第一，矩阵 $F(p \times q)$ 对矩阵 $X(m \times n)$ 的导数应包含所有 $mnpq$ 个偏导数 $\frac{\partial F_{kl}}{\partial X_{ij}}$ ，从而不损失信息；第二，导数与微分有简明的联系，因为在计算导数和应用中需要这个联系；第三，导数有简明的从整体出发的算法。我们先定义向量 \boldsymbol{f}

$(p \times 1)$ 对向量 $\boldsymbol{x} (m \times 1)$ 的导数 $\frac{\partial \boldsymbol{f}}{\partial \boldsymbol{x}} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_2}{\partial x_1} & \cdots & \frac{\partial f_p}{\partial x_1} \\ \frac{\partial f_1}{\partial x_2} & \frac{\partial f_2}{\partial x_2} & \cdots & \frac{\partial f_p}{\partial x_2} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_1}{\partial x_m} & \frac{\partial f_2}{\partial x_m} & \cdots & \frac{\partial f_p}{\partial x_m} \end{bmatrix} (m \times p)$ ，有 $d\boldsymbol{f} = \frac{\partial \boldsymbol{f}^T}{\partial \boldsymbol{x}} d\boldsymbol{x}$ ；再定义

矩阵的（按列优先）向量化 $\text{vec}(X) = [X_{11}, \dots, X_{m1}, X_{12}, \dots, X_{m2}, \dots, X_{1n}, \dots, X_{mn}]^T (mn \times 1)$ ，并定义矩阵 F 对矩阵 X 的导数 $\frac{\partial F}{\partial X} = \frac{\partial \text{vec}(F)}{\partial \text{vec}(X)} (mn \times pq)$ 。导数与微分有联系

$\text{vec}(dF) = \frac{\partial F^T}{\partial X} \text{vec}(dX)$ 。几点说明如下：

1. 按此定义，标量 f 对矩阵 $X(m \times n)$ 的导数 $\frac{\partial f}{\partial X}$ 是 $mn \times 1$ 向量，与上篇的定义不兼容，不过二者容易相互转换。为避免混淆，用记号 $\nabla_X f$ 表示上篇定义的 $m \times n$ 矩阵，则有 $\frac{\partial f}{\partial X} = \text{vec}(\nabla_X f)$ 。虽然本篇的技术可以用于标量对矩阵求导这种特殊情况，但使用上篇中的技术更方便。读者可以通过上篇中的算例试验两种方法的等价转换。
2. 标量对矩阵的二阶导数，又称Hessian矩阵，定义为 $\nabla_X^2 f = \frac{\partial^2 f}{\partial X^2} = \frac{\partial \nabla_X f}{\partial X} (mn \times mn)$ ，是对称矩阵。对向量 $\frac{\partial f}{\partial \boldsymbol{x}}$ 或矩阵 $\nabla_X f$ 求导都可以得到Hessian矩阵，但从矩阵 $\nabla_X f$ 出发更方便。
3. $\frac{\partial F}{\partial X} = \frac{\partial \text{vec}(F)}{\partial X} = \frac{\partial F}{\partial \text{vec}(X)} = \frac{\partial \text{vec}(F)}{\partial \text{vec}(X)}$ ，求导时矩阵被向量化，弊端是这在一定程度破坏了矩阵的结构，会导致结果变得形式复杂；好处是多元微积分中关于梯度、Hessian矩阵的结论可以沿用过来，只需将矩阵向量化。例如优化问题中，牛顿法的更新 ΔX ，满足 $\text{vec}(\Delta X) = -(\nabla_X^2 f)^{-1} \text{vec}(\nabla_X f)$ 。

4. 在资料中，矩阵对矩阵的导数还有 $\frac{\partial F}{\partial X} = [\frac{\partial F_{kl}}{\partial X_{ij}}]$ ，

赞同 1342

201 条评论

分享

收藏



$\frac{\partial \mathbf{F}}{\partial \mathbf{X}} = \left[\frac{\partial \mathbf{F}}{\partial x_{ij}} \right] (m \times n \times q)$ ，它能兼容上篇中的标量对矩阵导数的定义，但微分与导数的联系

($d\mathbf{F}$ 等于 $\frac{\partial \mathbf{F}}{\partial \mathbf{X}}$ 中逐个 $m \times n$ 子块分别与 $d\mathbf{X}$ 做内积) 不够简明，不便于计算和应用。资料[5]综述了以上定义，并批判它们是坏的定义，能配合微分运算的才是好的定义。

然后来建立运算法则。仍然要利用导数与微分的联系 $\text{vec}(d\mathbf{F}) = \frac{\partial \mathbf{F}^T}{\partial \mathbf{X}} \text{vec}(d\mathbf{X})$ ，求微分的方法与上篇相同，而从微分得到导数需要一些向量化的技巧：

- 1. 线性： $\text{vec}(\mathbf{A} + \mathbf{B}) = \text{vec}(\mathbf{A}) + \text{vec}(\mathbf{B})$ 。
- 2. 矩阵乘法： $\text{vec}(\mathbf{AXB}) = (\mathbf{B}^T \otimes \mathbf{A})\text{vec}(\mathbf{X})$ ，其中 \otimes 表示Kronecker积， $\mathbf{A}(m \times n)$ 与 $\mathbf{B}(p \times q)$ 的Kronecker积是 $\mathbf{A} \otimes \mathbf{B} = [\mathbf{A}_{ij}\mathbf{B}] (mp \times nq)$ 。此式证明见张贤达《矩阵分析与应用》第107-108页。
- 3. 转置： $\text{vec}(\mathbf{A}^T) = \mathbf{K}_{mn}\text{vec}(\mathbf{A})$ ， \mathbf{A} 是 $m \times n$ 矩阵，其中 $\mathbf{K}_{mn} (mn \times mn)$ 是交换矩阵(commutation matrix)，将按列优先的向量化变为按行优先的向量化。例如 $\mathbf{K}_{22} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}$ ， $\text{vec}(\mathbf{A}^T) = \begin{bmatrix} \mathbf{A}_{11} \\ \mathbf{A}_{12} \\ \mathbf{A}_{21} \\ \mathbf{A}_{22} \end{bmatrix}$ ， $\text{vec}(\mathbf{A}) = \begin{bmatrix} \mathbf{A}_{11} \\ \mathbf{A}_{21} \\ \mathbf{A}_{12} \\ \mathbf{A}_{22} \end{bmatrix}$ 。
- 4. 逐元素乘法： $\text{vec}(\mathbf{A} \odot \mathbf{X}) = \text{diag}(\mathbf{A})\text{vec}(\mathbf{X})$ ，其中 $\text{diag}(\mathbf{A}) (mn \times mn)$ 是用 \mathbf{A} 的元素（按列优先）排成的对角阵。

观察一下可以断言，若矩阵函数 \mathbf{F} 是矩阵 \mathbf{X} 经加减乘法、逆、行列式、逐元素函数等运算构成，则使用相应的运算法则对 \mathbf{F} 求微分，再做向量化并使用技巧将其它项交换至 $\text{vec}(d\mathbf{X})$ 左侧，对照导数与微分的联系 $\text{vec}(d\mathbf{F}) = \frac{\partial \mathbf{F}^T}{\partial \mathbf{X}} \text{vec}(d\mathbf{X})$ ，即能得到导数。

特别地，若矩阵退化为向量，对照导数与微分的联系 $d\mathbf{f} = \frac{\partial \mathbf{f}^T}{\partial \mathbf{x}} d\mathbf{x}$ ，即能得到导数。

再谈一谈复合：假设已求得 $\frac{\partial \mathbf{F}}{\partial \mathbf{Y}}$ ，而 \mathbf{Y} 是 \mathbf{X} 的函数，如何求 $\frac{\partial \mathbf{F}}{\partial \mathbf{X}}$ 呢？从导数与微分的联系入手， $\text{vec}(d\mathbf{F}) = \frac{\partial \mathbf{F}^T}{\partial \mathbf{Y}} \text{vec}(d\mathbf{Y}) = \frac{\partial \mathbf{F}^T}{\partial \mathbf{Y}} \frac{\partial \mathbf{Y}^T}{\partial \mathbf{X}} \text{vec}(d\mathbf{X})$ ，可以推出链式法则 $\frac{\partial \mathbf{F}}{\partial \mathbf{X}} = \frac{\partial \mathbf{Y}}{\partial \mathbf{X}} \frac{\partial \mathbf{F}}{\partial \mathbf{Y}}$ 。

和标量对矩阵的导数相比，矩阵对矩阵的导数形式更加复杂，从不同角度出发常会得到形式不同的结果。有一些Kronecker积和交换矩阵相关的恒等式，可用来做等价变形：

- 1. $(\mathbf{A} \otimes \mathbf{B})^T = \mathbf{A}^T \otimes \mathbf{B}^T$ 。
- 2. $\text{vec}(\mathbf{a}\mathbf{b}^T) = \mathbf{b} \otimes \mathbf{a}$ 。
- 3. $(\mathbf{A} \otimes \mathbf{B})(\mathbf{C} \otimes \mathbf{D}) = (\mathbf{AC}) \otimes (\mathbf{BD})$ 。可以对 $\mathbf{F} = \mathbf{r}^T \mathbf{R}^T \mathbf{Y} \mathbf{A} \mathbf{C}$ 求导来证明。一方面，直接求得 $\frac{\partial \mathbf{F}}{\partial \mathbf{X}} = (\mathbf{AC}) \otimes (\mathbf{BD})$ ；另一方面

式法则得到 $\frac{\partial F}{\partial X} = (A \otimes B)(C \otimes D)$ 。



4. $K_{mn} = K_{nm}^T, K_{mn}K_{nm} = I$ 。

5. $K_{pm}(A \otimes B)K_{nq} = B \otimes A$ ，A是 $m \times n$ 矩阵，B是 $p \times q$ 矩阵。可以对 AXB^T 做向量化来证明，一方面， $\text{vec}(AXB^T) = (B \otimes A)\text{vec}(X)$ ；另一方面，

$$\text{vec}(AXB^T) = K_{pm}\text{vec}(BX^TA^T) = K_{pm}(A \otimes B)\text{vec}(X^T) = K_{pm}(A \otimes B)K_{nq}\text{vec}(X)。$$

接下来演示一些算例。

例1: $F = AX$ ，X是 $m \times n$ 矩阵，求 $\frac{\partial F}{\partial X}$ 。

解：先求微分： $dF = AdX$ ，再做向量化，使用矩阵乘法的技巧，注意在 dX 右侧添加单位阵：

$$\text{vec}(dF) = \text{vec}(AdX) = (I_n \otimes A)\text{vec}(dX)，\text{对照导数与微分的联系得到 } \frac{\partial F}{\partial X} = I_n \otimes A^T。$$

特例：如果X退化为向量，即 $f = Ax$ ，则根据向量的导数与微分的关系 $df = \frac{\partial f^T}{\partial x} dx$ ，得到

$$\frac{\partial f}{\partial x} = A^T。$$

例2: $f = \log|X|$ ，X是 $n \times n$ 矩阵，求 $\nabla_X f$ 和 $\nabla_X^2 f$ 。

解：使用上篇中的技术可求得 $\nabla_X f = X^{-1T}$ 。为求 $\nabla_X^2 f$ ，先求微分： $d\nabla_X f = -(X^{-1}dXX^{-1})^T$ ，再做向量化，使用转置和矩阵乘法的技巧

$\text{vec}(d\nabla_X f) = -K_{nn}\text{vec}(X^{-1}dXX^{-1}) = -K_{nn}(X^{-1T} \otimes X^{-1})\text{vec}(dX)$ ，对照导数与微分的联系，得到 $\nabla_X^2 f = -K_{nn}(X^{-1T} \otimes X^{-1})$ ，注意它是对称矩阵。在X是对称矩阵时，可简化为 $\nabla_X^2 f = -X^{-1} \otimes X^{-1}$ 。

例3: $F = A \exp(XB)$ ，A是 $l \times m$ 矩阵，X是 $m \times n$ 矩阵，B是 $n \times p$ 矩阵，exp为逐元素函数，求 $\frac{\partial F}{\partial X}$ 。

解：先求微分： $dF = A(\exp(XB) \odot (dXB))$ ，再做向量化，使用矩阵乘法的技巧：

$\text{vec}(dF) = (I_p \otimes A)\text{vec}(\exp(XB) \odot (dXB))$ ，再用逐元素乘法的技巧：

$\text{vec}(dF) = (I_p \otimes A)\text{diag}(\exp(XB))\text{vec}(dXB)$ ，再用矩阵乘法的技巧：

$\text{vec}(dF) = (I_p \otimes A)\text{diag}(\exp(XB))(B^T \otimes I_m)\text{vec}(dX)$ ，对照导数与微分的联系得到

$$\frac{\partial F}{\partial X} = (B \otimes I_m)\text{diag}(\exp(XB))(I_p \otimes A^T)。$$

例4【一元logistic回归】： $l = -y\mathbf{x}^T\mathbf{w} + \log(1 + \exp(\mathbf{x}^T\mathbf{w}))$ ，求 $\nabla_{\mathbf{w}} l$ 和 $\nabla_{\mathbf{w}}^2 l$ 。其中y是取值0或1的标量， \mathbf{x}, \mathbf{w} 是 $n \times 1$ 列向量。


▲ 赞同 1342 ▼

● 201 条评论

➤ 分享

★ 收藏

..

解：使用上篇中的技术可求得 $\nabla_w l = \mathbf{x}(\sigma(\mathbf{x}^T \mathbf{w}) - y)$ ，其中 $\sigma(a) = \frac{\exp(a)}{1 + \exp(a)}$ 为sigmoid函数 
为求 $\nabla_w^2 l$ ，先求微分： $d\nabla_w l = \mathbf{x}\sigma'(\mathbf{x}^T \mathbf{w})\mathbf{x}^T d\mathbf{w}$ ，其中 $\sigma'(a) = \frac{\exp(a)}{(1 + \exp(a))^2}$ 为sigmoid函数的
导数，对照导数与微分的联系，得到 $\nabla_w^2 l = \mathbf{x}\sigma'(\mathbf{x}^T \mathbf{w})\mathbf{x}^T$ 。

推广：样本 $(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)$ ， $l = \sum_{i=1}^N (-y_i \mathbf{x}_i^T \mathbf{w} + \log(1 + \exp(\mathbf{x}_i^T \mathbf{w})))$ ，求 $\nabla_w l$ 和 $\nabla_w^2 l$ 。有

两种方法，解1：先对每个样本求导，然后相加；解2：定义矩阵 $\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^T \\ \vdots \\ \mathbf{x}_N^T \end{bmatrix}$ ，向量 $\mathbf{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_N \end{bmatrix}$ ，

将 l 写成矩阵形式 $l = -\mathbf{y}^T \mathbf{X} \mathbf{w} + \mathbf{1}^T \log(1 + \exp(\mathbf{X} \mathbf{w}))$ ，进而可以使用上篇中的技术求得
 $\nabla_w l = \mathbf{X}^T (\sigma(\mathbf{X} \mathbf{w}) - \mathbf{y})$ 。为求 $\nabla_w^2 l$ ，先求微分，再用逐元素乘法的技巧：
 $d\nabla_w l = \mathbf{X}^T (\sigma'(\mathbf{X} \mathbf{w}) \odot (\mathbf{X} d\mathbf{w})) = \mathbf{X}^T \text{diag}(\sigma'(\mathbf{X} \mathbf{w})) \mathbf{X} d\mathbf{w}$ ，对照导数与微分的联系，得到
 $\nabla_w^2 l = \mathbf{X}^T \text{diag}(\sigma'(\mathbf{X} \mathbf{w})) \mathbf{X}$ 。

例5【多元logistic回归】： $l = -\mathbf{y}^T \log \text{softmax}(\mathbf{W} \mathbf{x}) = -\mathbf{y}^T \mathbf{W} \mathbf{x} + \log(\mathbf{1}^T \exp(\mathbf{W} \mathbf{x}))$ ，求 $\nabla_w l$ 和 $\nabla_w^2 l$ 。其中 \mathbf{y} 是除一个元素为1外其它元素为0的 $m \times 1$ 列向量， \mathbf{W} 是 $m \times n$ 矩阵， \mathbf{x} 是 $n \times 1$ 列向量， l 是标量。

解：上篇中已求得 $\nabla_w l = (\text{softmax}(\mathbf{W} \mathbf{x}) - \mathbf{y}) \mathbf{x}^T$ 。为求 $\nabla_w^2 l$ ，先求微分：定义 $\mathbf{a} = \mathbf{W} \mathbf{x}$ ，
 $d\nabla_w l = \left(\frac{\exp(\mathbf{a}) \odot d\mathbf{a}}{\mathbf{1}^T \exp(\mathbf{a})} - \frac{\exp(\mathbf{a})(\mathbf{1}^T (\exp(\mathbf{a}) \odot d\mathbf{a}))}{(\mathbf{1}^T \exp(\mathbf{a}))^2} \right) \mathbf{x}^T = \left(\frac{\text{diag}(\exp(\mathbf{a}))}{\mathbf{1}^T \exp(\mathbf{a})} - \frac{\exp(\mathbf{a}) \exp(\mathbf{a})^T}{(\mathbf{1}^T \exp(\mathbf{a}))^2} \right) d\mathbf{a} \mathbf{x}^T$
 $= (\text{diag}(\text{softmax}(\mathbf{a})) - \text{softmax}(\mathbf{a}) \text{softmax}(\mathbf{a})^T) d\mathbf{a} \mathbf{x}^T$ ，注意这里化简去掉逐元素乘法，第一项
中 $\exp(\mathbf{a}) \odot d\mathbf{a} = \text{diag}(\exp(\mathbf{a})) d\mathbf{a}$ ，第二项中 $\mathbf{1}^T (\exp(\mathbf{a}) \odot d\mathbf{a}) = \exp(\mathbf{a})^T d\mathbf{a}$ 。定义矩阵
 $\mathbf{D}(\mathbf{a}) = \text{diag}(\text{softmax}(\mathbf{a})) - \text{softmax}(\mathbf{a}) \text{softmax}(\mathbf{a})^T$ ， $d\nabla_w l = \mathbf{D}(\mathbf{a}) d\mathbf{a} \mathbf{x}^T = \mathbf{D}(\mathbf{W} \mathbf{x}) d\mathbf{W} \mathbf{x} \mathbf{x}^T$ ，
做向量化并使用矩阵乘法的技巧，得到 $\nabla_w^2 l = (\mathbf{x} \mathbf{x}^T) \otimes \mathbf{D}(\mathbf{W} \mathbf{x})$ 。

最后做个总结。我们发展了从整体出发的矩阵求导的技术，**导数与微分的联系是计算的枢纽**，标量
对矩阵的导数与微分的联系是 $d\mathbf{f} = \text{tr}(\nabla_{\mathbf{X}}^T \mathbf{f} d\mathbf{X})$ ，先对 \mathbf{f} 求微分，再使用迹技巧可求得导数，特别
地，标量对向量的导数与微分的联系是 $d\mathbf{f} = \nabla_{\mathbf{x}}^T \mathbf{f} d\mathbf{x}$ ；矩阵对矩阵的导数与微分的联系是
 $\text{vec}(d\mathbf{F}) = \frac{\partial \mathbf{F}^T}{\partial \mathbf{X}} \text{vec}(d\mathbf{X})$ ，先对 \mathbf{F} 求微分，再使用向量化的技巧可求得导数，特别地，向量对向量
的导数与微分的联系是 $d\mathbf{f} = \frac{\partial \mathbf{f}^T}{\partial \mathbf{x}} d\mathbf{x}$ 。

参考资料：

1. 张贤达. 矩阵分析与应用. 清华大

▲ 赞同 1342 ▼

● 201 条评论

➤ 分享

★ 收藏


..

2. Fackler, Paul L. "Notes on matrix calculus." *North Carolina State University*(2005).

3. Petersen, Kaare Brandt, and Michael Syskind Pedersen. "The matrix cookbook." *Technical University of Denmark* 7 (2008): 15.

4. HU, Pili. "Matrix Calculus: Derivation and Simple Application." (2012).


5. Magnus, Jan R., and Heinz Neudecker. "Matrix Differential Calculus with Applications in Statistics and Econometrics." Wiley, 2019.



编辑于 03-12


矩阵分析 机器学习 优化

推荐阅读




特征值和特征向量[MIT线代第二十一课]

忆臻 发表于机器学习算...



特征向量与线性变换

稻谷 发表于计算机的数...



矩阵的几

二圈妹

201 条评论

⇌ 切换为时间排序

写下你的评论...



精选评论 (1)



王赞 Maigo

2017-01-22

矩阵对矩阵求导的结果中有好多Kronecker积啊.....不过也没办法，把一个本来是四维的东西压成二维已经不容易了。

👍 21

▲ 赞同 1342 ▼

● 201 条评论

➦ 分享

★ 收藏

⋮


评论 (201)



 James Liu2017-01-21


先赞为敬

 1


 方不觉2017-01-21


赞

 赞


 王赞 Maigo2017-01-22

矩阵对矩阵求导的结果中有好多Kronecker积啊.....不过也没办法，把一个本来是四维的东西压成两维已经不容易了。

 21


 李元气2017-01-22

我只是想吐槽知乎这个狗屎编辑器到现在都不支持 MathJax，真是废物。怕是坦桑尼亚的民族风情网站都支持 MathJax 了。可能知乎的前端一没高分屏，二没大学文凭。

 32

 依树影魅 回复 李元气2019-12-19

坦桑尼亚的民族风情网站网址是？

 2

 scarff 回复 依树影魅01-07

哈哈哈哈哈

 赞

 Shinji Fujiwara2017-03-10

赞

 赞

 排骨郎2017-03-16


例3中，与B的转置做 kronecker product 的单位矩阵应该是 I_m 不是 I_n

 2

 长躯鬼侠 (作者) 回复 排骨郎2017-03-16

多谢指正

 赞

 几许风雨

 赞同 1342  201 条评论  分享  收藏 ...

nice

👍 赞



木太木大

2017-04-22

例3的公式没有渲染出来

👍 赞



Johnqc Zhang

2017-05-11

求问向量对矩阵的求导是否也适用这套方法？

👍 赞



长躯鬼侠 (作者) 回复 Johnqc Zhang

2017-05-11

适用啊 向量可以看成矩阵的特例

👍 赞



f8411cjh 回复 长躯鬼侠 (作者)

2018-12-17

如果x是向量，是否有 $VEC(x)=VEC(xT)$ ？

👍 赞

展开其他 1 条回复



DreamYun

2017-08-08

看完上下篇，是否可以总结出如下：对于复合函数求导，如果是标量函数对矩阵求导，没有链式法则可用；如果是矩阵对矩阵求导，有链式法则可以套用。

👍 赞



长躯鬼侠 (作者) 回复 DreamYun

2017-08-08

你可以这么理解。不过链式法则就是源自多次求微分，所以只是形式不同，没有本质的区别。

👍 2



DreamYun

2017-08-08

或者可以这么表达：如果不论标量还是矩阵（包括向量）对矩阵的求导，如果是按照篇二的做法，首先都列向量化（vec），然后求导。那么对于这种形式的求导，是可以适用复合函数的链式求导法则。其它形式的求导方法，可能不适用复合函数求导链式法则。

👍 1



陌烛

2017-08-26

你好，请问下，为何例二中，f对X的二阶导没有进行转置？在原文（例二中）：“对照导数与微分的关系得到……”后面的那个式子

👍 赞

▲ 赞同 1342 ▼

● 201 条评论

➦ 分享

★ 收藏

⋮



长躯鬼侠 (作者) 回复 陌烛
是对称矩阵，转置等于它自己。

2017-08-2

2



落叶的一生 回复 长躯鬼侠 (作者)
是算出来转置等于他自己嘛

02-19

赞

展开其他 1 条回复



陌烛
还有，请问下，我怎么确定我的转换矩阵的值是多少啊？

2017-08-26

赞



陌烛
你好，请问下，原文中有句话：“若矩阵函数F是矩阵X经加减乘法、行列式、逆、逐元素函数等运算构成，则使用相应的运算法则对F求微分，再做向量化并使用技巧将其它项交换至vec(dX)左侧，即能得到导数”，那么如果F是由X卷积操作得到的，那么，对于这个卷积的运算法则是什么呢？

2017-08-27

赞



长躯鬼侠 (作者) 回复 陌烛
对于卷积，你可以自己推导一下，运算法则也可以用卷积来表示，对full、valid模式在细节上有些差异。

2017-08-28

1



陌烛
你好，我还想知道下，克罗内克积和矩阵乘积，哪个的优先级大啊？

2017-08-27

赞



长躯鬼侠 (作者) 回复 陌烛
我没有指定Kronecker积和矩阵乘积哪个优先级高，所以都加括号了啊。

2017-08-28

赞



陌烛 回复 长躯鬼侠 (作者)
蟹蟹，我果然不适合推导数学公式

2017-09-07

赞

查看全部 9 条回复



孙培钦

赞同 1342

201 条评论


分享

收藏

..


我想问一下，假设我有个等式 $S = WX$ ， S 是 $m \times 1$ 向量， X 是 $n \times 1$ 向量， W 是 $m \times n$ 矩阵，使用上述的求导术去求 S 向量对 X 向量的导数，我得到的是一个 $n \times n$ 的单位阵与 W 转置的kronecker积啊，这个积的尺寸应该是 $nn \times mn$ ，明显不对啊。

👍 1

 长驱鬼侠 (作者) 回复 孙培钦 2017-09-29

$ds = W^T dx$ ， x 的右面是 1×1 的单位阵，不是 $n \times n$ 的。

👍 1

 暮日落流年 2017-12-10

收益匪浅，赞一个！

👍 赞

 引线小白 2017-12-11

能区分一下行列求导就更完美了，同时使用线性变换解释一下导数与微分的关系，可能更加恰当，和利于直觉。

👍 1

 neilfvhv 2017-12-27

问个问题， $\frac{\partial F}{\partial X} = \frac{\partial \text{vec} F}{\partial \text{vec} X}$ 这一步是怎么得到的？

👍 赞

 长驱鬼侠 (作者) 回复 neilfvhv 2017-12-27

这是定义

👍 赞