

博文

## EM算法(期望最大化算法)简介

已有 6592 次阅读 2019-8-1 00:12 | 个人分类:Algorithm | 系统分类:科研笔记 | EM算法, 机器学习, EM algorithm, 算法, 期望最大化

和HMM简介一样（有关HMM，隐马尔科夫模型的简介，请参见我的另一篇博文<http://blog.sciencenet.cn/blog-2970729-1188964.html>），我们还是通过一个例子引入EM算法(Expectation Maximization Algorithm)

## 1. 一个经典例子

我们有两枚硬币(coin A & coin B)，这两枚硬币是用特殊材质做的，硬币A抛出正面 (Head)和反面(Tail)的概率为 $\theta_A$ 和 $1-\theta_A$ ，硬币B抛出正面和反面的概率为 $\theta_B$  和 $1-\theta_B$ 。我们不知道 $\theta_A$ 和 $\theta_B$ ，因此想通过不断的抛硬币来推测出 $\theta_A$ 和 $\theta_B$ ，为了方便，写成向量形式：

$$\theta = (\theta_A, \theta_B).$$

因为有两枚硬币，我们随机地在硬币A和硬币B中挑一个(概率相等，各为50%)，然后再用选中的硬币独立地抛10次，为了使整个事件更具说服力，我们选硬币抛硬币的整个过程重复做了5次。因此，总的来说选了5次硬币，抛了 $5 \times 10 = 50$ 次。

选了5次硬币，每次记为 $z_i \in \{A, B\}$ ，5次合到一起记为 $z = (z_1, z_2, z_3, z_4, z_5)$ ；每选1次硬币(抛10次)，我们记录其中正面出现的次数 $x_i \in \{0, 1, \dots, 10\}$ ，5次合到一起记为 $x = (x_1, x_2, x_3, x_4, x_5)$ 。于是，很容易我们就可以评估出 $\theta_A$ ：

$$\theta_A = \frac{A \text{ 硬币抛出正面的次数}}{A \text{ 硬币抛出的总次数}}$$

这种通过观测来评估模型参数的方法称为**极大似然评估**(Maximum likelihood estimation)。

上面这个例子比较简单，是一个完备问题(complete data case)。如果上面这个例子中，已知 $x$ 向量，但是不知道 $z$ 向量，这时再来评估 $\theta_A$ 和 $\theta_B$ 。这类问题属于不完备问题(incomplete data case)，我们称未知的 $z$ 向量为**隐变量**(hidden variables)或者**潜在因素**(latent factors)。

注：我们可以想象一下，开篇的例子中，我们挑一枚硬币且记录下挑了什么硬币，再抛这枚硬币且记录下硬币的正反面。现在由于意外发生，挑硬币的那部分记录不幸遗失，只有硬币正反向次数的记录，让我们求解两枚硬币抛出正面的概率分别是多少。仔细一想，这个问题其实还是挺难的！聪明的人们想出了一个很直觉的解决办法——EM算法。

首先我们随便给定 $\theta_A$ 和 $\theta_B$ ，如果有先验知识也可以用先验知识。

$$\hat{\theta}^{(t)} = (\hat{\theta}_A^{(t)}, \hat{\theta}_B^{(t)})$$

基于这两个参数，计算这5次硬币A/B最可能的出现情况。再固定这5次硬币A/B抽取情况，估计 $\theta$ ，此时记为

$$\hat{\theta}^{(t+1)}$$

再不断重复这一过程直到收敛。

总之，EM算法轮流执行两个步骤：其一，在当前模型的前提下，猜测最可能的概率分布，例如推测硬币A/B的抽取概率和期望，这一步称为E-step；其二，在推测的结果基础上重新评估模型的参数，推测 $\theta_A$ 和 $\theta_B$ ，这一步称为M-step。

之所以称为E-step，是因为通常不需要在绝对完整的前提下来生成概率分布，而是在当前完整的情况下，计算"期望的(Expected)"的充分统计量。与此类似，之所以称为M-step，是因为模型的重新评估可以认为是使期望的log值"最大化(Maximization)"。

## 2. 数学推导

在推导之前我们需要一点数学知识：

### > Jensen's inequality

**Theorem 0.2 (Jensen's Inequality)** Let  $f(x)$  be a convex function defined on an interval  $I$ . If  $x_1, x_2, \dots, x_N \in I$  and  $\lambda_1, \lambda_2, \dots, \lambda_N \geq 0$  with  $\sum_{i=1}^N \lambda_i = 1$ ,


$$f\left(\sum_{i=1}^N \lambda_i x_i\right) \leq \sum_{i=1}^N \lambda_i f(x_i)$$

Alternatively, if  $f(x)$  is a convex function and  $X \in \{x_i : 1, \dots, N\}$  is a random variable with probabilities  $P(x_i)$  where  $\sum P(x_i) = 1$ , then,

$$f(E\{X\}) \leq E\{f(X)\}$$

$$f\left(\sum_{i=1}^N x_i P(x_i)\right) \leq \sum_{i=1}^N f(x_i) P(x_i)$$

对应的图形如下：



**问题：已知一组独立的样本 $x=\{x_1, x_2, x_3, \dots, x_m\}$ ，求模型 $p(x, z)$ 的参数 $\theta$ ，使 $p(x, z)$ 最大，其中 $z$ 是隐变量。**

开始推导：

因为log函数是单调递增的，所以求 $p(x, z)$ 的最大值，即求 $\log(p(x, z))$ 的最大值。完整的写出似然函数如下，即求 $L(\theta)$ 最大时参数 $\theta$ 的值：

$$\begin{aligned}\ell(\theta) &= \sum_{i=1}^m \log p(x; \theta) \\ &= \sum_{i=1}^m \log \sum_z p(x, z; \theta).\end{aligned}$$

因为 $z$ 通常观测不到，这使得问题比较复杂，无法直接求 $L(\theta)$ 的最大值。我们采用EM算法，构建 $L(\theta)$ 的下界(E-step)，再优化下界(M-step)，并不断重复这一过程。

$$\sum_i \log p(x^{(i)}; \theta) = \sum_i \log \sum_{z^{(i)}} p(x^{(i)}, z^{(i)}; \theta) \quad (1)$$

$$= \sum_i \log \sum_{z^{(i)}} Q_i(z^{(i)}) \frac{p(x^{(i)}, z^{(i)}; \theta)}{Q_i(z^{(i)})} \quad (2)$$

$$\geq \sum_i \sum_{z^{(i)}} Q_i(z^{(i)}) \log \frac{p(x^{(i)}, z^{(i)}; \theta)}{Q_i(z^{(i)})} \quad (3)$$

(1)式是上述所求的。上述公式来自Andrew Ng[3]，Andrew Ng喜欢用上标表示index，可能和我们的习惯写法有点不一致，在此不展开，大家可以简单地将 $x^{(i)}$ 看成 $x_i$

(2)式是分子分母同乘了一个 $Q_i(z^{(i)})$ 它是一种分布，而且

$$\begin{aligned}\sum_z Q_i(z) &= 1 \\ Q_i(z) &\geq 0\end{aligned}$$

(3)由第2个式子到第3个式子的推导如下：

令 $f(x) = \log(x)$ ， $j = z^{(i)}$ ， $\lambda_j = Q_i(j)$ ，其中 $\sum \lambda_j = 1$ ，且 $\lambda_j \geq 0$ 。而且

$$\beta_i = \frac{p(x^{(i)}, z^{(i)}; \theta)}{Q_i(z^{(i)})}$$

那么第2个式子到第3个式子推导如下：

$$\begin{aligned}\sum_i \log p(x^{(i)}; \theta) &= \sum_i \log \sum_{z^{(i)}} Q_i(z^{(i)}) \frac{p(x^{(i)}, z^{(i)}; \theta)}{Q_i(z^{(i)})} \\ &= \sum_i f\left(\sum_j \lambda_j \beta_j\right) \\ &\geq \sum_i \sum_j \lambda_j f(\beta_j) \\ &= \sum_i \sum_{z^{(i)}} Q_i(z^{(i)}) \log \frac{p(x^{(i)}, z^{(i)}; \theta)}{Q_i(z^{(i)})}\end{aligned}$$

当且仅当以下等式成立时， $L(\theta)$ 取得极大值：

$$\frac{p(x^{(i)}, z^{(i)}; \theta)}{Q_i(z^{(i)})} = c$$

其中 $c$ 表示常数。也即

$$Q_i(z^{(i)}) \propto p(x^{(i)}, z^{(i)}; \theta).$$

又因为 $Q_i(z^{(i)})$ 是概率分布，按照定义

$$\sum_z Q_i(z^{(i)}) = 1$$

所以有

$$\begin{aligned} Q_i(z^{(i)}) &= \frac{p(x^{(i)}, z^{(i)}; \theta)}{\sum_z p(x^{(i)}, z; \theta)} \\ &= \frac{p(x^{(i)}, z^{(i)}; \theta)}{p(x^{(i)}; \theta)} \\ &= p(z^{(i)} | x^{(i)}; \theta) \end{aligned}$$

**综上，不断重复以下两个步骤，直到收敛：**

(E-step) For each  $i$ , set

$$Q_i(z^{(i)}) := p(z^{(i)} | x^{(i)}; \theta).$$


(M-step) Set

$$\theta := \arg \max_{\theta} \sum_i \sum_{z^{(i)}} Q_i(z^{(i)}) \log \frac{p(x^{(i)}, z^{(i)}; \theta)}{Q_i(z^{(i)})}.$$

其中:=表示当前等于，也即覆盖之前的值

### 3. 用Chuong[1]文章中的实例详细计算一下

#### b Expectation maximization



⊙  $i=0$ 时，令

$$\begin{aligned} \hat{\theta}_A^{(0)} &= 0.60 \\ \hat{\theta}_B^{(0)} &= 0.50 \end{aligned}$$

**E-Step:**

(1) 计算第一次选硬币，且投出的结果为H-T-T-T-H-H-T-H-T-H时，选的是硬币A的概率

根据二项分布定义，如果第一次选的是A硬币，投10次有5次为正面的概率为：

$$P(HTTTHHTH|A) = C_{10}^5 (0.6)^5 (1 - 0.6)^5$$

同理，可计算出如果第一次选的是B硬币，投10次有5次为正面的概率：

$$P(HTTTHHTH|B) = C_{10}^5 (0.5)^5 (1 - 0.5)^5$$

再由贝叶斯定律可计算出，投币结果为H-T-T-T-H-H-T-H-T-H，且这一结果是硬币A投出的概率为：

$$\begin{aligned} P(A|HTTTHHTH) &= \frac{P(HTTTHHTH|A)P(A)}{P(HTTTHHTH|A)P(A) + P(HTTTHHTH|B)P(B)} \\ &= \frac{C_{10}^5 (0.6)^5 (1 - 0.6)^5 \times 0.5}{C_{10}^5 (0.6)^5 (1 - 0.6)^5 \times 0.5 + C_{10}^5 (0.5)^5 (1 - 0.5)^5 \times 0.5} \\ &\approx 0.45 \end{aligned}$$

注意：其中P(A)和P(B)都为0.5，因为抽取A硬币和抽取B硬币是等可能的。

同理，投币结果为H-T-T-T-H-H-T-H-T-H，且这一结果是硬币B投出的概率为：

$$P(B|HTTTHHTH) \approx 0.55$$

(2) 再依次计算第二到第五次选硬币时，抽取到A/B硬币的概率。所有结果汇总如下表：

Observation	Coin A	Coin B
HTTTHHTH	0.45	0.55
HHHTHHHH	0.80	0.20
HTHHHHTH	0.73	0.27
HTHTTHTT	0.35	0.65
THHHTHHH	0.65	0.35
Total	2.98	2.02
Score	21.24	11.76

其中，Coin A列表示投出该行硬币正反面情况下，推测是用A硬币来投的概率。

Total行是计算的5次试验的总和，而Score行的计算如下：

$$\text{Score} = (0.45 \times 5) + (0.8 \times 9) + (0.73 \times 8) + (0.35 \times 4) + (0.65 \times 7) = 21.24$$

仔细回想，这里的Score其实就是5次选币（50次投币）事件的期望值(Expectation)！以上整个过程也正是在计算 $P(z^{(i)} | x^{(i)}; \theta)$ ，即

每次观测(Observation)索引  $\Rightarrow i$

当前 $\theta$ 参数条件  $\Rightarrow (\theta_A, \theta_B)$

每次观测，如H-T-T-T-H-H-T-H-T-H  $\Rightarrow x^{(i)}$

挑选的硬币 (Coin A, Coin B)  $\Rightarrow z^{(i)}$

的概率 $P(z^{(i)} | x^{(i)}; \theta)$

另外，我们可以在文中看到如下表格，计算的也是一样的，以第二行为例Coin A列的2.2H表示第一次选硬币，再抛10次时硬币为H的总和 $0.45 \times 5$ ；Coin B列的2.8H表示 $0.55 \times 5$

Coin A	Coin B
$\approx 2.2 \text{ H}, 2.2 \text{ T}$	$\approx 2.8 \text{ H}, 2.8 \text{ T}$
$\approx 7.2 \text{ H}, 0.8 \text{ T}$	$\approx 1.8 \text{ H}, 0.2 \text{ T}$
$\approx 5.9 \text{ H}, 1.5 \text{ T}$	$\approx 2.1 \text{ H}, 0.5 \text{ T}$
$\approx 1.4 \text{ H}, 2.1 \text{ T}$	$\approx 2.6 \text{ H}, 3.9 \text{ T}$
$\approx 4.5 \text{ H}, 1.9 \text{ T}$	$\approx 2.5 \text{ H}, 1.1 \text{ T}$
$\approx 21.3 \text{ H}, 8.6 \text{ T}$	$\approx 11.7 \text{ H}, 8.4 \text{ T}$

同理，我们也可以算出观测到是HTTTHHTHTH时Coin A抛出反面的概率得分2.2T

### M-Step:

再计算当前假设下，硬币A投正面的概率，以及硬币B投正面的概率，即

$$\hat{\theta}_A^{(1)} \approx \frac{21.3}{21.3 + 8.6} \approx 0.71$$

$$\hat{\theta}_B^{(1)} \approx \frac{11.7}{11.7 + 8.4} \approx 0.58$$

从 $\theta^{(i)}$ 到 $\theta^{(i+1)}$ 的过程为什么叫做极大化(Maximization)? 其实这里有个认证：每次迭代的过程(从 $\theta^{(i)}$ 到 $\theta^{(i+1)}$ )，都会使 $P(z^{(i)} | x^{(i)}; \theta)$ 增大，越来越接近或者达到局部极值

>再将 $\theta^{(i+1)}$ 作为参数，不断重复上述步骤，直到结果收敛。

经过10次重复之后，算出如下结果：

$$\hat{\theta}_A^{(10)} \approx 0.80$$

$$\hat{\theta}_B^{(10)} \approx 0.52$$

最后，需要强调的是EM也有自身的缺陷：

- (1) 最终的结果与初始值的选取有关，不同的初始值可能得到不同的参数估计值
- (2) 很可能会陷入局部最优解，而无法达到全局最优解

### 总结：

本文简约地介绍了EM算法，旨在深入浅出，面向的对象是算法小白(如我一般)。留下两个问题，有兴趣的读者可以继续探索，如果有时间后续我也会整理出来：

- (1) EM算法的收敛性：E-Step和M-Step不断重复，最后是否会收敛？

(2) EM算法的应用，例如高斯混合模型、HMM中的第三个问题 (这个问题我会尽快整理到博文中，敬请期待)等。

参考材料：

[1] Chuong B Do, Serafim Batzoglou. What is the expectation maximization algorithm?

[2] Konstantinos G. Derpanis . Jensen’s Inequality

[3] Andrew Ng. CS229 Lecture notes

[4] <https://ynorm.com/blog/expectation-maximization/>

转载本文请联系原作者获取授权，同时请注明本文来自卢锐科学网博客。  
链接地址：<http://blog.sciencenet.cn/blog-2970729-1191928.html>

上一篇：隐马尔科夫模型简介(三)  
下一篇：隐马尔科夫模型简介(四)

收藏

当前推荐数：**0**

推荐到博客首页

评论 (0 个评论)

该博文允许注册用户评论 请点击登录